

HỌC VIỆN HÀNG KHÔNG VIỆT NAM

KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO

KHAI THÁC DỮ LIỆU

**SỬ DỤNG CÁC THUẬT TOÁN PHÂN LOẠI PHÂN CỤM TRÊN
TẬP DỮ LIỆU HÀNH VI MUA SẮM KHÁCH HÀNG**

Giảng viên hướng dẫn: ThS. Trần Anh Tuấn

Sinh viên/ Nhóm sinh viên thực hiện: Nhóm 10

Mã số sinh viên:

Lớp: 010100087302

TP.Hồ Chí Minh, tháng 03/2025

HỌC VIỆN HÀNG KHÔNG VIỆT NAM

KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO

KHAI THÁC DỮ LIỆU

**SỬ DỤNG CÁC THUẬT TOÁN PHÂN LOẠI PHÂN CỤM TRÊN
TẬP DỮ LIỆU HÀNH VI MUA SẮM KHÁCH HÀNG**

Giảng viên hướng dẫn: ThS. Trần Anh Tuấn

Sinh viên/ Nhóm sinh viên thực hiện: Nhóm 10

Mã số sinh viên:

Lớp: 010100087302

Thành phố Hồ Chí Minh, tháng 03/2025

Danh sách Nhóm:

STT	Họ và tên	MSSV	Lớp	Ghi chú
1	Trịnh Ngọc Nhất	2254810077	22ĐHTT02	Nhóm Trưởng
2	Lê Nguyên Thành	2254810053	22ĐHTT02	Thành Viên
3	Đàm Thị Ngọc Minh	2254810098	22ĐHTT02	Thành Viên
4	Phạm Trịnh Xuân Duy	2254810088	22ĐHTT02	Thành Viên
5	Trần Minh Quân	2254810055	22ĐHTT02	Thành Viên
6	Trần Minh Quân	2254810073	22ĐHTT02	Thành Viên

Cán bộ chấm thi 1 <i>(ký và ghi rõ họ tên)</i>	Cán bộ chấm thi 2 <i>(ký và ghi rõ họ tên)</i>
Cán bộ chấm thi phúc khảo 1 <i>(ký và ghi rõ họ tên)</i>	Cán bộ chấm thi phúc khảo 2 <i>(ký và ghi rõ họ tên)</i>

MỤC LỤC

MỞ ĐẦU	vi
CHƯƠNG 1. GIỚI THIỆU	1
1.1. Lý do chọn đề tài	1
1.2. Mục tiêu đề tài	1
1.3. Phạm vi đề tài	1
1.4 Đối tượng nghiên cứu	1
1.5. Phương pháp nghiên cứu	2
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	3
2.1. Ngôn ngữ lập trình Python	3
2.1.1. Khái niệm và lịch sử hình thành	3
2.1.2. Đặc điểm	4
2.2. Kaggle	4
2.2.1. Giới thiệu về Kaggle	4
2.2.2. Tính năng của Kaggle	5
2.3. Phân cụm K-means	6
2.3.1. Giới thiệu về Phân cụm	6
2.3.2. Thuật toán K-means	7
2.3.3. Ưu điểm và Nhược điểm của thuật toán K-means	9
2.4. Phân cụm phân cấp (Hierarchical Clustering)	9
2.4.1. Giới thiệu tổng quan:	10
2.4.2. Nguyên lý hoạt động:	10
2.4.3. Ưu điểm và nhược điểm:	10
2.4.4. Ứng dụng:	11

2.5. Phân cụm bằng SVM	11
2.5.1. Khái niệm cơ bản của SVM	11
2.5.2. Các đặc điểm của phân cụm SVM	12
2.5.3. Ưu điểm và Nhược điểm của SVM trong phân cụm	13
2.6. Thuật toán K-Nearest Neighbors (KNN)	14
2.6.1. Giới thiệu tổng quan	14
2.6.2. Nguyên lý hoạt động	14
2.6.3. Các bước thực hiện	15
2.6.4. Ưu điểm	15
2.6.5. Nhược điểm	15
2.7. Các chỉ số đánh giá trong bài toán phân loại	15
2.7.1. Accuracy (Độ chính xác)	16
2.7.2. Precision (Độ chính xác riêng)	17
2.7.3. Recall (Độ nhạy)	17
2.7.4. F1-Score	18
CHƯƠNG 3. PHÂN TÍCH HỆ THỐNG VÀ XÂY DỰNG SẢN PHẨM	19
3.1. Phân tích hệ thống	19
3.1.1. Quy trình hoạt động	19
3.1.2. Tập dữ liệu sử dụng	19
3.1.3. Trực quan hóa dữ liệu	21
3.2. Xây dựng sản phẩm	23
3.2.1 Tiền xử lý dữ liệu	23
3.2.2. Phân loại bằng SVM	24

3.2.3. Phân loại bằng KNN	26
3.2.4. Phân cụm bằng K-means	28
3.2.5. Thuật toán Hierarchical Clustering (phân cụm phân cấp)	29
3.2.6. Đánh giá kết quả	31
KẾT LUẬN	32
DANH MỤC TÀI LIỆU THAM KHẢO	35

DANH MỤC BẢNG BIỂU, HÌNH ẢNH

Bảng 3.1. Các thuộc tính của tập dữ liệu	20
Hình 2.1. Ngôn ngữ lập trình Python	3
Hình 2.2. Nền tảng Kaggle	4
Hình 3.1. Quy trình hoạt động	19
Hình 3.2. Cấu trúc tập dữ liệu	20
Hình 3.3. Trực quan hóa mối quan hệ giữa Age và Purchase Amount	21
Hình 3.4. Trực quan hóa mối quan hệ giữa Gender và Purchase Amount	22
Hình 3.5. Đọc tập dữ liệu	23
Hình 3.6. Mã hóa One-Hot Encoding	24
Hình 3.7. Kết quả phân loại thuật toán SVM	26
Hình 3.8. Kết quả phân loại thuật toán KNN	27
Hình 3.9. Đồ thị Elbow của K-means	29
Hình 3.10. Biểu đồ Dendrogram	31
Hình 3.11. Kết quả phân cụm Hierarchical và K-Means Clustering	32

MỞ ĐẦU

Trong bối cảnh cạnh tranh ngày càng gay gắt trên thị trường, việc hiểu rõ nhu cầu và hành vi của khách hàng trở thành yếu tố quan trọng giúp các doanh nghiệp duy trì lợi thế cạnh tranh. Phân cụm khách hàng là một trong những phương pháp khai phá dữ liệu hiệu quả, cho phép doanh nghiệp phân loại khách hàng thành các nhóm dựa trên những đặc điểm tương đồng, từ đó áp dụng các chiến lược tiếp thị và chăm sóc khách hàng phù hợp.

Mục tiêu chính của đề tài "**Phân cụm trên tập dữ liệu hành vi mua sắm khách hàng**" là xây dựng mô hình phân loại khách hàng dựa trên hai yếu tố chính: **thu nhập hàng năm** và **điểm chi tiêu**. Dựa trên kết quả phân cụm, các doanh nghiệp có thể xác định nhóm khách hàng mục tiêu, điều chỉnh các chương trình khuyến mãi, ưu đãi, và nâng cao trải nghiệm mua sắm. Trong đề tài này, chúng tôi áp dụng thuật toán **K-Means**, **SVM**, **KNn** và **Hierarchical Clustering** để thực hiện phân cụm và đánh giá kết quả dựa trên các chỉ số như **Accuracy**, **Precision**, **Recall** và **F1-Score** nhằm xác định độ chính xác của mô hình.

Ngoài ra, chúng tôi cũng sẽ thảo luận về tiềm năng của việc ứng dụng các thuật toán đã áp dụng trong phân cụm khách hàng, so sánh ưu điểm và hạn chế của từng phương pháp. Từ đó, đề tài cung cấp những đóng góp quan trọng cho việc phát triển chiến lược kinh doanh và tiếp thị của doanh nghiệp.

CHƯƠNG 1. GIỚI THIỆU

1.1. Lý do chọn đề tài

Trong bối cảnh thị trường ngày càng cạnh tranh, việc hiểu rõ hành vi và sở thích của khách hàng trở thành yếu tố quan trọng để doanh nghiệp duy trì lợi thế cạnh tranh. Phân khúc khách hàng cho phép doanh nghiệp không chỉ nhận diện và phân loại khách hàng theo các tiêu chí như tuổi, thu nhập, mà còn giúp tối ưu hóa các chiến lược tiếp thị và cung cấp dịch vụ cá nhân hóa. Với sự phát triển của khoa học dữ liệu và các phương pháp khai thác dữ liệu, việc áp dụng các kỹ thuật phân khúc khách hàng, cụ thể là K-Means Clustering, mang lại khả năng khai thác giá trị từ dữ liệu khổng lồ của khách hàng, giúp doanh nghiệp đưa ra quyết định dựa trên dữ liệu một cách hiệu quả hơn. Điều này không chỉ có lợi cho doanh nghiệp trong việc tối ưu hóa doanh thu, mà còn có thể áp dụng vào nhiều lĩnh vực khác như y tế, giáo dục, và thương mại điện tử.

1.2. Mục tiêu đề tài

Mục tiêu của đề tài là xây dựng một hệ thống phân khúc khách hàng dựa trên các thông số như tuổi và thu nhập hàng năm, từ đó phân loại các nhóm khách hàng có hành vi mua sắm tương đồng. Hệ thống này sẽ hỗ trợ doanh nghiệp trong việc xác định các chiến lược tiếp thị hiệu quả hơn. Ngoài ra, đề tài sẽ áp dụng thuật toán K-Means Clustering, một phương pháp phổ biến trong lĩnh vực phân tích dữ liệu, nhằm đưa ra các phân tích chính xác về đặc điểm của từng nhóm khách hàng.

1.3. Phạm vi đề tài

Phạm vi của đề tài tập trung vào việc nghiên cứu và phân tích dữ liệu khách hàng của một trung tâm thương mại, bao gồm các đối tượng khách hàng thuộc mọi độ tuổi và giới tính. Dữ liệu khách hàng được thu thập qua thẻ thành viên với các thông tin cơ bản như ID khách hàng, độ tuổi, thu nhập hàng năm và chỉ số chi tiêu. Đề tài sẽ giới hạn trong việc nghiên cứu các phương pháp phân cụm dữ liệu sử dụng thuật toán K-Means và các yếu tố ảnh hưởng trực tiếp đến việc phân loại khách hàng dựa trên các thông số đã chọn.

1.4 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là tập dữ liệu khách hàng, bao gồm các thông số về tuổi, thu nhập và hành vi chi tiêu. Tập dữ liệu này sẽ được phân tích để tìm ra các nhóm khách hàng có đặc điểm tương đồng, phục vụ cho quá trình phân cụm.

1.5. Phương pháp nghiên cứu

Đề tài sử dụng phương pháp thu thập thông tin từ tập dữ liệu `shopping_behavior_updated.csv`. Dữ liệu liên quan đến khách hàng của một trung tâm thương mại, được thu thập qua thẻ thành viên, bao gồm các thông tin như ID khách hàng, tuổi, giới tính, thu nhập hàng năm và chỉ số chi tiêu. Các phương pháp phân tích định lượng sẽ được áp dụng, bao gồm sử dụng thuật toán K-Means Clustering để phân cụm khách hàng. Ngoài ra, phương pháp thực nghiệm sẽ được tiến hành thông qua việc áp dụng thuật toán trên tập dữ liệu thực tế và đánh giá kết quả dựa trên các tiêu chí như sự tương đồng trong cụm và khoảng cách giữa các cụm.

1.6. Bố cục đề tài

Chương 2 trình bày cơ sở lý thuyết, bao gồm các khái niệm và lý thuyết liên quan đến phân khúc khách hàng. Trong chương này, chúng tôi sẽ giới thiệu các phương pháp phân cụm, cùng với thuật toán K-Means Clustering, là phương pháp chính được áp dụng trong đề tài. Đồng thời, chương này cũng thảo luận về nguyên lý hoạt động của K-Means Clustering, các ưu nhược điểm của thuật toán, cũng như ứng dụng của nó trong việc phân tích dữ liệu khách hàng.

Chương 3, chúng tôi giới thiệu quá trình phân tích hệ thống và xây dựng sản phẩm. Chương này sẽ tập trung vào việc tiền xử lý dữ liệu, bao gồm việc làm sạch dữ liệu, chọn lọc các thuộc tính như độ tuổi và thu nhập hàng năm của khách hàng để làm đầu vào cho quá trình phân cụm. Chương này cũng sẽ giải thích chi tiết về quá trình xây dựng mô hình, tối ưu hóa số cụm và đánh giá hiệu quả của mô hình phân cụm thông qua các chỉ số đánh giá như khoảng cách giữa các cụm và sự đồng nhất trong cụm.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

Trong quá trình nghiên cứu và triển khai đề tài "Phân cụm khách hàng" để thực hiện phân cụm khách hàng, ngôn ngữ lập trình Python được sử dụng nhờ vào tính linh hoạt và khả năng hỗ trợ các thư viện khoa học dữ liệu mạnh mẽ. Nguồn dữ liệu được khai thác từ Kaggle, một nền tảng phổ biến cung cấp các bộ dữ liệu phong phú và đa dạng. Về thuật toán, đề tài này áp dụng thuật toán K-means để thực hiện phân cụm khách hàng và kết hợp với SVM (Support Vector Machine), Hierarchical Clustering và Linear Regression để so sánh và đánh giá hiệu quả phân loại dữ liệu. Để đo lường hiệu suất của các mô hình, các chỉ số Accuracy, Precision, Recall và F1-Score được sử dụng nhằm đánh giá độ chính xác, khả năng phát hiện và hiệu suất tổng thể của từng phương pháp.

2.1. Ngôn ngữ lập trình Python

2.1.1. Khái niệm và lịch sử hình thành

Python là một ngôn ngữ lập trình được sử dụng rộng rãi trong nhiều lĩnh vực như phát triển các trang web, khoa học dữ liệu và cả trí tuệ nhân tạo (AI). Lập trình viên chọn Python bởi vì nó dễ học, hiệu quả và có thể hoạt động trên nhiều hệ thống khác nhau. Python có mã nguồn mở, được phân phối miễn phí và tích hợp tốt với các nền tảng khác, giúp tăng tốc độ phát triển phần mềm.



Hình 2.1. Ngôn ngữ lập trình Python

2.1.2. Đặc điểm

Python có nhiều đặc điểm nổi bật, giúp nó trở thành một trong những ngôn ngữ lập trình phổ biến nhất hiện nay:

- Ngôn ngữ thông dịch: Python chạy mã theo từng dòng, điều này nghĩa là chương trình được thực thi ngay lập tức sau khi mã được nhập. Nếu có lỗi, chương trình sẽ dừng lại, giúp việc sửa lỗi trở nên nhanh chóng và dễ dàng hơn.
- Dễ tiếp cận và sử dụng: Python có cú pháp gần giống với tiếng Anh thông thường, làm cho nó dễ đọc và hiểu.
- Tính linh hoạt cao: Lập trình viên không cần khai báo kiểu dữ liệu trước, Python sẽ tự động nhận diện khi mã được thực thi. Điều này giúp việc lập trình trở nên nhanh gọn hơn.
- Ngôn ngữ cấp cao: Python có cú pháp gần gũi với ngôn ngữ con người, giúp lập trình viên không phải lo lắng về các khía cạnh kỹ thuật phức tạp như quản lý bộ nhớ hoặc kiến trúc hệ thống.
- Hỗ trợ lập trình hướng đối tượng: Python xem tất cả mọi thứ trong chương trình là đối tượng, nhưng cũng cho phép sử dụng các phương pháp lập trình khác như lập trình hàm hay lập trình cấu trúc.

2.2. Kaggle

2.2.1. Giới thiệu về Kaggle

Kaggle là một nền tảng trực tuyến cung cấp môi trường cho các nhà khoa học dữ liệu và các kỹ sư máy học chia sẻ kiến thức, và thực hành kỹ năng phân tích dữ liệu. Được ra mắt vào năm 2010, Kaggle nhanh chóng trở thành một cộng đồng lớn và thu hút sự tham gia của các chuyên gia trong lĩnh vực khoa học dữ liệu trên toàn thế giới.



Hình 2.2. Nền tảng Kaggle

Ban đầu, Kaggle nổi tiếng nhờ các cuộc thi khoa học dữ liệu, nơi các công ty và tổ chức có thể đăng tải các vấn đề thực tế cần giải quyết và các nhà khoa học dữ liệu sẽ cạnh tranh để tìm ra mô hình tốt nhất. Tuy nhiên, ngoài các cuộc thi, Kaggle còn cung cấp nhiều nguồn tài nguyên giá trị như **Datasets**, **Kernels** (công cụ viết mã trực tuyến), và các khóa học để giúp người dùng phát triển kỹ năng phân tích dữ liệu của mình.

Nền tảng Kaggle không chỉ giúp người dùng học hỏi và phát triển kỹ năng, mà còn là nơi giúp các tổ chức, doanh nghiệp tìm ra các giải pháp sáng tạo và hiệu quả cho các bài toán lớn trong nhiều lĩnh vực như tài chính, y tế, và công nghệ.

2.2.2. Tính năng của Kaggle

2.2.2.1. Datasets

Một trong những tính năng nổi bật của Kaggle là cung cấp một thư viện dữ liệu khổng lồ và phong phú. Người dùng có thể truy cập hàng ngàn tập dữ liệu thuộc nhiều lĩnh vực khác nhau như y tế, tài chính, marketing, và nhiều lĩnh vực khác. Các tập dữ liệu trên Kaggle không chỉ mang tính học thuật mà còn có nguồn gốc từ các doanh nghiệp và tổ chức lớn.

- **Đặc điểm của Datasets trên Kaggle:**
 - Người dùng có thể **tải lên** và **chia sẻ** dữ liệu của mình với cộng đồng, từ đó tạo nên một kho tài nguyên mở rộng và đa dạng.
 - Kaggle cung cấp các công cụ trực tuyến để **tương tác trực tiếp** với dữ liệu mà không cần phải tải về. Điều này giúp người dùng tiết kiệm thời gian và nhanh chóng bắt tay vào phân tích.
 - Mỗi dataset đều đi kèm với phần mô tả chi tiết và hướng dẫn sử dụng, giúp người dùng dễ dàng nắm bắt cấu trúc và nội dung của dữ liệu.

Datasets trên Kaggle là nguồn tài nguyên quý giá không chỉ cho người mới bắt đầu học hỏi, mà còn cho các chuyên gia nghiên cứu và thử nghiệm các mô hình máy học trên dữ

liệu thực tế. Với hàng loạt dữ liệu từ các dự án thực tế, Kaggle đã trở thành nơi lý tưởng cho việc **thực hành và thử nghiệm các mô hình**.

2.2.2.2 Kernels

Kaggle Kernels là một công cụ trực tuyến hỗ trợ viết mã, nơi người dùng có thể chạy trực tiếp các đoạn mã trên nền tảng mà không cần thiết lập môi trường máy tính cục bộ. Công cụ này hỗ trợ nhiều ngôn ngữ lập trình phổ biến như Python và R, cùng với hàng loạt thư viện khoa học dữ liệu như Pandas, Numpy, Scikit-learn, TensorFlow,...

- **Lợi ích của Kernels:**

- Người dùng có thể **thử nghiệm nhanh chóng** các mô hình phân tích và máy học ngay trên nền tảng mà không cần cài đặt bất kỳ phần mềm nào.
- Các **mã nguồn** trong Kernels có thể được chia sẻ công khai để cộng đồng tham khảo và học hỏi. Điều này thúc đẩy sự phát triển chung của cộng đồng Kaggle.
- Ngoài ra, Kaggle cũng hỗ trợ **GPU** để tăng tốc độ xử lý các bài toán học sâu (deep learning), giúp người dùng có thể chạy các mô hình lớn hơn và phức tạp hơn.

Kernels không chỉ giúp người dùng làm việc hiệu quả hơn mà còn là một nơi lý tưởng để họ **chia sẻ kiến thức, tương tác với cộng đồng**, và học hỏi từ những người khác.

2.3. Phân cụm K-means

2.3.1. Giới thiệu về Phân cụm

Phân cụm (clustering) là một trong những kỹ thuật quan trọng nhất trong khai phá dữ liệu (data mining). Mục tiêu của phân cụm là chia dữ liệu thành các nhóm (cluster) sao cho các đối tượng trong cùng một nhóm có nhiều điểm chung với nhau và ít điểm chung với các đối tượng ở nhóm khác. Kỹ thuật này được sử dụng rộng rãi trong nhiều lĩnh vực như tiếp thị, y học, công nghệ thông tin, và nhiều ngành công nghiệp khác.

Phân cụm giúp các nhà khoa học dữ liệu khám phá ra các cấu trúc hoặc mẫu ẩn trong dữ liệu mà không cần sự hướng dẫn trước, tức là phân cụm là một dạng học không giám sát (unsupervised learning). Một trong những thuật toán phân cụm phổ biến và dễ áp dụng nhất chính là **K-means clustering**.

2.3.2. Thuật toán K-means

Thuật toán **K-means** là một phương pháp phân cụm dựa trên centroid (tâm cụm) được sử dụng phổ biến trong khai phá dữ liệu và học máy. Mục tiêu chính của thuật toán K-means là chia dữ liệu thành K cụm sao cho các điểm dữ liệu trong mỗi cụm có độ tương đồng cao hơn với các điểm trong cùng cụm so với các cụm khác.

2.3.2.1. Khái niệm cơ bản

Thuật toán K-means hoạt động dựa trên khái niệm tính khoảng cách giữa các điểm dữ liệu. Điểm dữ liệu sẽ được gán vào cụm có centroid gần nó nhất. Centroid của mỗi cụm sẽ được tính toán dựa trên trung bình khoảng cách của tất cả các điểm trong cụm đó.

Cho một tập dữ liệu có n điểm dữ liệu $x_1, x_2, \dots, x_n$, thuật toán K-means chia tập dữ liệu này thành K cụm. Mỗi cụm sẽ có một centroid tương ứng, được tính là trung bình của tất cả các điểm dữ liệu thuộc về cụm đó. Thuật toán sẽ tối ưu hóa để tổng khoảng cách giữa các điểm dữ liệu và centroid của cụm chứa chúng là nhỏ nhất.

2.3.2.2. Các bước thực hiện thuật toán K-means

Thuật toán K-means được thực hiện qua các bước sau:

1. **Khởi tạo:** Ban đầu, chọn ngẫu nhiên K centroid (tâm cụm) từ tập dữ liệu. Các điểm centroid này có thể được chọn ngẫu nhiên hoặc sử dụng một số phương pháp khác như K-means++ để cải thiện kết quả phân cụm.
2. **Phân cụm:** Mỗi điểm dữ liệu được gán vào cụm có centroid gần nhất, thường sử dụng khoảng cách Euclidean làm thước đo khoảng cách.

Công thức tính khoảng cách Euclidean giữa hai điểm dữ liệu x_i và c_j (tâm cụm j) là:

$$d(x_i, c_j) = \sqrt{\sum_{k=1}^n (x_{ik} - c_{jk})^2}$$

Trong đó, x_{ik} và c_{jk} là các thành phần của x_i và c_j .

3. **Cập nhật centroid:** Sau khi tất cả các điểm dữ liệu đã được gán vào các cụm, tính lại centroid của từng cụm bằng cách lấy trung bình tất cả các điểm dữ liệu trong cụm đó. Centroid của cụm j được tính bằng:

$$c_j = \frac{1}{n_j} \sum_{x_i \in C_j} x_i$$

Trong đó, n_j là số lượng điểm dữ liệu thuộc cụm j , C_j là cụm thứ j , và x_i là điểm dữ liệu thuộc cụm đó.

4. **Lặp lại:** Lặp lại quá trình phân cụm và cập nhật centroid cho đến khi centroid không thay đổi nữa hoặc sự thay đổi là nhỏ và không đáng kể.

5. **Dừng thuật toán:** Thuật toán kết thúc khi đạt tới trạng thái hội tụ, tức là các centroid không thay đổi hoặc đạt số vòng lặp tối đa.

2.3.2.3. Công thức hàm mất mát trong K-means

Hàm mất mát (cost function) trong K-means thường được gọi là **tổng phương sai nội cụm** (within-cluster sum of squares - WCSS), biểu diễn tổng bình phương khoảng cách giữa các điểm dữ liệu và centroid của cụm chứa nó:

$$J = \sum_{j=1}^K \sum_{x_i \in C_j} \|x_i - c_j\|^2$$

Mục tiêu của thuật toán là tối thiểu hóa hàm mất mát này để đảm bảo các điểm dữ liệu trong mỗi cụm là gần nhau nhất có thể.

2.3.3. Ưu điểm và Nhược điểm của thuật toán K-means

2.3.3.1. Ưu điểm

- **Đơn giản và dễ hiểu:** K-means là một trong những thuật toán phân cụm dễ hiểu và dễ triển khai nhất. Các bước thuật toán rất rõ ràng, giúp người mới bắt đầu có thể nhanh chóng nắm bắt.
- **Tính toán hiệu quả:** Thuật toán K-means có độ phức tạp tính toán thấp so với các thuật toán phân cụm khác. Với n là số điểm dữ liệu và k là số cụm, độ phức tạp của thuật toán K-means là $O(nk)$.
- **Khả năng mở rộng:** K-means có khả năng mở rộng để làm việc với các bộ dữ liệu lớn, nhờ khả năng xử lý tính toán nhanh và đơn giản.

2.3.3.2. Nhược điểm

- **Phụ thuộc vào giá trị K:** Thuật toán yêu cầu phải xác định trước số lượng cụm K, điều này có thể gây khó khăn nếu không có thông tin cụ thể về dữ liệu. Việc lựa chọn số lượng cụm không đúng có thể dẫn đến kết quả phân cụm không tốt.
- **Nhạy cảm với giá trị khởi tạo:** Kết quả của K-means có thể khác nhau khi khởi tạo các centroid ban đầu khác nhau. Để khắc phục điều này, phương pháp **K-means++** đã được đề xuất để cải thiện việc khởi tạo centroid.
- **Chỉ áp dụng tốt với dữ liệu hình cầu:** K-means giả định rằng các cụm có dạng hình cầu và các cụm có kích thước tương tự nhau, do đó nó không hoạt động tốt với các cụm có hình dạng phức tạp hoặc không đồng đều.
- **Dễ bị ảnh hưởng bởi ngoại lệ:** Các điểm dữ liệu ngoại lệ có thể ảnh hưởng lớn đến việc tính toán centroid và dẫn đến kết quả phân cụm không chính xác.

2.4. Phân cụm phân cấp (Hierarchical Clustering)

2.4.1. Giới thiệu tổng quan:

- Phân cụm phân cấp là một thuật toán phân cụm không giám sát, xây dựng một hệ thống phân cấp các cụm.
- Thuật toán tạo ra một cây phân cấp (dendrogram) thể hiện mối quan hệ giữa các cụm.
- Có hai phương pháp chính của phân cụm phân cấp:
 - Phân cụm phân cấp kết tụ (agglomerative hierarchical clustering): Bắt đầu với mỗi điểm dữ liệu là một cụm riêng biệt và hợp nhất các cụm gần nhau nhất cho đến khi chỉ còn một cụm duy nhất.
 - Phân cụm phân cấp phân chia (divisive hierarchical clustering): Bắt đầu với tất cả các điểm dữ liệu trong một cụm duy nhất và chia các cụm thành các cụm nhỏ hơn cho đến khi mỗi điểm dữ liệu là một cụm riêng biệt.

2.4.2. Nguyên lý hoạt động:

- Khoảng cách giữa các cụm: Khoảng cách giữa các cụm được tính toán bằng các phương pháp như:
 - Khoảng cách liên kết đơn (single linkage): Khoảng cách giữa hai điểm gần nhau nhất trong hai cụm.
 - Khoảng cách liên kết hoàn toàn (complete linkage): Khoảng cách giữa hai điểm xa nhau nhất trong hai cụm.
 - Khoảng cách liên kết trung bình (average linkage): Khoảng cách trung bình giữa tất cả các cặp điểm trong hai cụm.
 - Khoảng cách centroid: Khoảng cách giữa trung tâm của 2 cụm.
- Cây phân cấp (dendrogram): Cây phân cấp là một biểu đồ hình cây thể hiện quá trình hợp nhất hoặc phân chia các cụm. Chiều cao của các nhánh trong cây phân cấp thể hiện khoảng cách giữa các cụm.
- Lựa chọn số lượng cụm: Số lượng cụm được lựa chọn bằng cách cắt cây phân cấp tại một mức độ phù hợp.

2.4.3. Ưu điểm và nhược điểm:

- Ưu điểm:
 - Không cần xác định trước số lượng cụm.
 - Cung cấp thông tin về cấu trúc phân cấp của dữ liệu.
 - Có thể được sử dụng với nhiều loại dữ liệu khác nhau.
- Nhược điểm:
 - Tốn nhiều thời gian tính toán đối với dữ liệu lớn.
 - Khó khăn trong việc xử lý dữ liệu nhiễu.
 - Kết quả có thể thay đổi tùy thuộc vào phương pháp tính khoảng cách.


2.4.4. Ứng dụng:

- Phân tích gen
- Phân loại tài liệu
- Phân tích mạng xã hội
- Phân khúc khách hàng

2.5. Phân cụm bằng SVM

2.5.1. Khái niệm cơ bản của SVM

SVM là một thuật toán học máy mạnh mẽ và phổ biến được sử dụng để giải quyết các bài toán phân loại và hồi quy. Trong phân loại có giám sát, SVM tìm kiếm một siêu phẳng tối ưu trong không gian đặc trưng để phân chia dữ liệu thành các lớp. SVM thực hiện việc này bằng cách tối đa hóa khoảng cách (margin) giữa các điểm dữ liệu gần nhất của hai lớp và siêu phẳng đó, đảm bảo rằng dữ liệu được phân loại một cách rõ ràng và tối ưu.



Hình 2.3: Phân loại bằng thuật toán SVM

Mặc dù nguyên bản của SVM được áp dụng trong bài toán phân loại, nhưng nó có thể được sử dụng trong phân cụm thông qua biến thể của nó, được gọi là **Support Vector Clustering (SVC)**. Trong SVC, thay vì sử dụng một siêu phẳng để phân loại dữ liệu thành các lớp, SVC sử dụng các siêu cầu (hypersphere) để phân cụm dữ liệu thành các nhóm khác nhau dựa trên mật độ của các điểm dữ liệu.

2.5.2. Các đặc điểm của phân cụm SVM

2.5.2.1. Kernel Trick

Một trong những điểm mạnh nhất của SVM, bao gồm cả trong phân cụm, là khả năng sử dụng **kernel trick**. Kernel trick cho phép thuật toán hoạt động tốt với các dữ liệu phi tuyến, bằng cách ánh xạ dữ liệu lên không gian đặc trưng mà không cần tính toán trực tiếp tọa độ của điểm trong không gian đó. Các kernel phổ biến được sử dụng trong phân cụm SVM bao gồm:

- **Linear Kernel:** Phù hợp khi dữ liệu có thể phân chia tuyến tính trong không gian đặc trưng gốc.
- **Polynomial Kernel:** Ánh xạ dữ liệu lên không gian có bậc đa thức cao hơn, giúp phân chia dữ liệu phi tuyến.
- **Gaussian RBF Kernel:** Kernel hàm cơ sở xuyên tâm (RBF) là một trong những kernel phổ biến nhất, đặc biệt hiệu quả trong các trường hợp phân cụm với dữ liệu phi tuyến.

Kernel trick giúp SVM mở rộng khả năng từ việc chỉ phân chia các dữ liệu tuyến tính sang phân chia dữ liệu có cấu trúc phức tạp hơn, giúp cải thiện hiệu quả của quá trình phân cụm trong các bài toán thực tiễn.

2.5.2.2. Khoảng cách giữa siêu phẳng và siêu cầu

Sự khác biệt quan trọng giữa SVM và SVC trong phân cụm là việc sử dụng siêu cầu thay vì siêu phẳng để phân chia dữ liệu. Trong SVM phân loại, một siêu phẳng được sử dụng để tối đa hóa khoảng cách giữa hai lớp dữ liệu. Trong SVC, thay vì phân chia dữ liệu bằng các siêu phẳng, thuật toán tạo ra các siêu cầu, giúp nhận diện và phân cụm các điểm dữ liệu dựa trên mật độ và sự phân tán của chúng trong không gian đặc trưng.

2.5.2.3. Không yêu cầu số cụm trước

Một ưu điểm khác của phân cụm SVC so với K-means là thuật toán này không yêu cầu người dùng phải biết trước số lượng cụm KKK. Điều này đặc biệt hữu ích trong những trường hợp mà dữ liệu không có thông tin rõ ràng về số lượng phân cụm hoặc không có sự phân chia đồng đều. SVC tự động tìm kiếm các cụm dựa trên phân bố tự nhiên của dữ liệu.

2.5.3. Ưu điểm và Nhược điểm của SVM trong phân cụm

2.5.3.1. Ưu điểm

- **Xử lý tốt dữ liệu phi tuyến:** Nhờ vào kernel trick, SVC có khả năng xử lý tốt dữ liệu phi tuyến và có cấu trúc phức tạp, điều mà các thuật toán phân cụm khác như K-means có thể gặp khó khăn.
- **Không yêu cầu số cụm trước:** SVC không cần biết trước số lượng cụm, giúp tiết kiệm thời gian trong các bài toán phân cụm với dữ liệu chưa rõ ràng.
- **Làm việc tốt với các tập dữ liệu có nhiễu:** SVC có thể xử lý tốt các tập dữ liệu có nhiễu và ngoại lệ nhờ khả năng tạo ra các siêu cầu bao quanh các điểm dữ liệu và phân chia chúng dựa trên mật độ.

2.5.3.2. Nhược điểm

- **Độ phức tạp tính toán cao:** Quá trình ánh xạ dữ liệu lên không gian đặc trưng và tính toán các siêu cầu có thể đòi hỏi tài nguyên tính toán lớn, đặc biệt là với các tập dữ liệu lớn.

- **Cần tinh chỉnh các tham số:** SVC yêu cầu người dùng phải tinh chỉnh các tham số như độ rộng của siêu cầu, loại kernel sử dụng, và các siêu tham số khác, điều này có thể phức tạp và tốn thời gian.
- **Khả năng phân cụm bị giới hạn trong một số trường hợp đặc biệt:** Mặc dù SVC có khả năng xử lý tốt dữ liệu phi tuyến, nhưng trong một số trường hợp dữ liệu có cấu trúc đặc biệt hoặc yêu cầu các cụm có kích thước khác nhau, thuật toán có thể không hiệu quả bằng các phương pháp khác.

2.6. Thuật toán K-Nearest Neighbors (KNN)

2.6.1. Giới thiệu tổng quan

Thuật toán K-Nearest Neighbors (KNN) là một thuật toán học máy giám sát (supervised learning) đơn giản nhưng hiệu quả, được sử dụng rộng rãi trong cả bài toán phân loại (classification) và hồi quy (regression). KNN là một thuật toán "lười" (lazy learning), nghĩa là nó không xây dựng mô hình một cách rõ ràng trong giai đoạn huấn luyện. Thay vào đó, nó lưu trữ toàn bộ dữ liệu huấn luyện và thực hiện tính toán chỉ khi cần dự đoán nhãn cho một điểm dữ liệu mới.

2.6.2. Nguyên lý hoạt động

Nguyên lý cơ bản của KNN là dự đoán nhãn của một điểm dữ liệu mới dựa trên nhãn của k điểm dữ liệu gần nhất trong tập huấn luyện. "Gần nhất" được định nghĩa bằng một độ đo khoảng cách, phổ biến nhất là khoảng cách Euclidean.

- **Phân loại (Classification):**
 - Thuật toán tìm k điểm dữ liệu gần nhất với điểm dữ liệu mới.
 - Nhãn của điểm dữ liệu mới được dự đoán là nhãn phổ biến nhất trong số k điểm gần nhất.
- **Hồi quy (Regression):**
 - Thuật toán tìm k điểm dữ liệu gần nhất với điểm dữ liệu mới.

- Giá trị dự đoán của điểm dữ liệu mới là giá trị trung bình (hoặc trung vị) của giá trị của k điểm gần nhất.

2.6.3. Các bước thực hiện

1. **Chọn giá trị k :** Giá trị k là số lượng láng giềng gần nhất được xem xét. Việc chọn giá trị k phù hợp là rất quan trọng và ảnh hưởng lớn đến hiệu suất của thuật toán.
2. **Tính toán khoảng cách:** Tính toán khoảng cách giữa điểm dữ liệu mới và tất cả các điểm dữ liệu trong tập huấn luyện.
3. **Tìm k láng giềng gần nhất:** Chọn k điểm dữ liệu gần nhất với điểm dữ liệu mới dựa trên khoảng cách đã tính toán.
4. **Dự đoán nhãn:**
 - Đối với bài toán phân loại, dự đoán nhãn của điểm dữ liệu mới dựa trên nhãn phổ biến nhất của k láng giềng gần nhất.
 - Đối với bài toán hồi quy, dự đoán giá trị của điểm dữ liệu mới dựa trên giá trị trung bình (hoặc trung vị) của k láng giềng gần nhất.

2.6.4. Ưu điểm

- Đơn giản và dễ hiểu.
- Không cần huấn luyện mô hình phức tạp.
- Hiệu quả với dữ liệu có ranh giới quyết định phi tuyến.
- Có thể áp dụng cho cả bài toán phân loại và hồi quy.

2.6.5. Nhược điểm

- Hiệu suất phụ thuộc nhiều vào việc chọn giá trị k .
- Tính toán khoảng cách tốn kém, đặc biệt với dữ liệu lớn.
- Dễ bị ảnh hưởng bởi nhiễu và các điểm ngoại lai.
- Hiệu suất giảm khi số chiều dữ liệu tăng (hiện tượng "lời nguyền của chiều cao").

2.7. Các chỉ số đánh giá trong bài toán phân loại

Việc đánh giá hiệu suất của mô hình là một bước cực kỳ quan trọng nhằm đảm bảo mô hình hoạt động hiệu quả và đáp ứng được yêu cầu của bài toán. Trong phần này, chúng ta sẽ tìm hiểu về các chỉ số đánh giá phổ biến bao gồm **Accuracy (Độ chính xác)**, **Precision (Độ chính xác riêng)**, **Recall (Độ nhạy)**, và **F1-Score**. Các chỉ số này thường được sử dụng trong các bài toán phân loại.

2.7.1. Accuracy (Độ chính xác)

Accuracy là chỉ số đơn giản nhất và thường được sử dụng để đánh giá mô hình học máy, đặc biệt là trong các bài toán phân loại. Accuracy đo lường tỷ lệ phần trăm các dự đoán đúng trong tổng số các dự đoán mà mô hình đưa ra.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Trong đó:

- **TP (True Positive)**: Số lượng mẫu được dự đoán là dương và thực tế cũng là dương.
- **TN (True Negative)**: Số lượng mẫu được dự đoán là âm và thực tế cũng là âm.
- **FP (False Positive)**: Số lượng mẫu được dự đoán là dương nhưng thực tế là âm (còn gọi là **lỗi dương tính giả**).
- **FN (False Negative)**: Số lượng mẫu được dự đoán là âm nhưng thực tế là dương (còn gọi là **lỗi âm tính giả**).

Ưu điểm: Accuracy là một chỉ số đơn giản và dễ hiểu, đặc biệt khi dữ liệu được phân phối đều giữa các lớp.

Nhược điểm: Accuracy có thể gây hiểu nhầm trong trường hợp dữ liệu mất cân bằng (imbalance), tức là số lượng mẫu trong các lớp không đồng đều. Ví dụ, nếu một lớp chiếm 95% dữ liệu, mô hình chỉ cần dự đoán tất cả các mẫu thuộc lớp đó cũng có thể đạt được accuracy cao nhưng không thực sự hiệu quả.

2.7.2. Precision (Độ chính xác riêng)

Precision là chỉ số đánh giá mức độ chính xác trong các dự đoán dương tính của mô hình, tức là trong tất cả các mẫu mà mô hình dự đoán là dương, có bao nhiêu mẫu thực sự dương.

$$Precision = \frac{TP}{TP + FP}$$

Trong đó:

- **TP (True Positive):** Số lượng dự đoán đúng của lớp dương.
- **FP (False Positive):** Số lượng dự đoán sai của lớp dương, nhưng thực tế là âm.

Ưu điểm: Precision có ý nghĩa trong các bài toán mà yêu cầu độ chính xác cao đối với các mẫu được dự đoán là dương.

Nhược điểm: Precision không xem xét đến các mẫu bị bỏ sót (False Negative), vì vậy nó không phải là chỉ số lý tưởng khi việc phát hiện đầy đủ các mẫu dương là quan trọng.

2.7.3. Recall (Độ nhạy)

Recall, còn được gọi là Sensitivity (Độ nhạy) hoặc True Positive Rate (Tỷ lệ dương tính thực), đo lường khả năng của mô hình trong việc tìm ra tất cả các mẫu dương trong tập dữ liệu, tức là trong tất cả các mẫu thực tế là dương, có bao nhiêu mẫu được dự đoán đúng.

$$Recall = \frac{TP}{TP + FN}$$

Trong đó:

- **TP (True Positive):** Số lượng dự đoán đúng của lớp dương.
- **FN (False Negative):** Số lượng dự đoán sai của lớp âm, nhưng thực tế là dương.

Recall là chỉ số quan trọng trong các bài toán mà việc bỏ sót các mẫu dương có thể gây ra hậu quả nghiêm trọng. Ví dụ, trong hệ thống phát hiện bệnh ung thư, việc bỏ sót một bệnh nhân thực sự mắc bệnh (False Negative) có thể dẫn đến tình trạng bệnh nhân không được điều trị kịp thời.

Ưu điểm: Recall có ý nghĩa trong các bài toán mà yêu cầu phát hiện đầy đủ các mẫu dương là quan trọng.

Nhược điểm: Recall không quan tâm đến các mẫu bị dự đoán sai dương (False Positive), do đó nếu chỉ tối ưu recall, mô hình có thể dự đoán tất cả các mẫu là dương và vẫn đạt recall cao.

2.7.4. F1-Score

F1-Score là chỉ số kết hợp giữa Precision và Recall, nhằm đạt được sự cân bằng giữa hai chỉ số này. F1-Score là trung bình điều hòa của Precision và Recall, giúp đánh giá mô hình một cách tổng quát hơn, đặc biệt là khi có sự mất cân bằng giữa Precision và Recall.

$$F1 - Score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

F1-Score sẽ đạt giá trị cao khi cả Precision và Recall đều cao và giảm nếu một trong hai chỉ số thấp. Do đó, F1-Score là một chỉ số quan trọng khi cần cân bằng giữa Precision và Recall.


Ưu điểm: F1-Score cung cấp một cái nhìn tổng quát về hiệu suất mô hình khi Precision và Recall có sự khác biệt đáng kể. Nó phù hợp cho các bài toán mất cân bằng dữ liệu.

Nhược điểm: F1-Score không thể cung cấp thông tin chi tiết về từng khía cạnh của Precision và Recall. Nếu Precision hoặc Recall có yêu cầu cụ thể trong bài toán, việc chỉ dựa vào F1-Score có thể không đủ để đánh giá mô hình một cách toàn diện.

CHƯƠNG 3. PHÂN TÍCH HỆ THỐNG VÀ XÂY DỰNG SẢN PHẨM

3.1. Phân tích hệ thống

3.1.1. Quy trình hoạt động



Hình 3.1. Quy trình hoạt động

Tại hình 3.1 mô tả quy trình hoạt động, bắt đầu từ việc thu thập tập dữ liệu từ Kaggle. Tiếp theo, dữ liệu được tiền xử lý nhằm đảm bảo chất lượng và tính nhất quán. Quá trình này bao gồm đọc và hiểu tập dữ liệu, xử lý các giá trị bị thiếu bằng các phương pháp như điền giá trị trung bình hoặc loại bỏ dữ liệu không hợp lệ, chuẩn hóa và chuyển đổi dữ liệu về định dạng phù hợp. Sau khi hoàn tất tiền xử lý, dữ liệu được phân cụm bằng các thuật toán khác nhau. Cuối cùng, kết quả phân cụm được đánh giá để xác định mức độ hiệu quả của từng phương pháp.

3.1.2. Tập dữ liệu sử dụng

Bộ dữ liệu xu hướng mua sắm của khách hàng là một sáng tạo tổng hợp từ nhiều doanh nghiệp, trung tâm thương mại và được tạo ra bằng AI để mô phỏng trải nghiệm mua sắm thực tế của khách hàng. Mục đích của của tập dữ liệu là thử nghiệm trong môi trường mô phỏng, khuyến khích hiểu sâu hơn về phân tích và diễn giải dữ liệu trong bối cảnh sở thích của người tiêu dùng và các tình huống bán lẻ.

Customer ID	Age	Gender	Item Purchased	Category	Purchase Amount (USD)	Location	Size	Color	Season	Review Rating	Subscription Status	Shipping Type	Discount Applied	Promo Code Used	Previous Purchases	Payment Method	Frequency of Purchases
2896	56	Female	Hoodie	Clothing	86	Montana	L	Green	Summer	4.60	No	Standard	No	No	29	Bank Transfer	Monthly
2752	27	Female	Dress	Clothing	52	Minnesota	S	Indigo	Fall	3.10	No	Free Shipping	No	No	50	Venmo	Monthly
1224	69	Male	Pants	Clothing	24	Kansas	L	Red	Winter	3.90	No	Free Shipping	Yes	Yes	21	Bank Transfer	Weekly
2485	60	Male	Hoodie	Clothing	97	New Hampshire	M	Green	Summer	4.80	No	2-Day Shipping	No	No	50	Cash	Every 3 Months
3286	58	Female	Hat	Accessories	31	Hawaii	XL	Magenta	Fall	4.60	No	Free Shipping	No	No	11	Cash	Weekly

Hình 3.2. Cấu trúc tập dữ liệu

Bộ dữ liệu xu hướng mua sắm của khách hàng bao gồm nhiều tính năng liên quan đến sở thích mua sắm của khách hàng, thu thập thông tin cần thiết cho các doanh nghiệp muốn nâng cao hiểu biết về cơ sở khách hàng của mình. Các tính năng bao gồm độ tuổi, giới tính, số tiền mua hàng, phương thức thanh toán ưa thích, tần suất mua hàng và xếp hạng phản hồi. Với bộ sưu tập 3900 bản ghi, bộ dữ liệu này đóng vai trò là nền tảng cho các doanh nghiệp muốn áp dụng thông tin chi tiết dựa trên dữ liệu để đưa ra quyết định tốt hơn và các chiến lược lấy khách hàng làm trung tâm.

Bảng 3.1. Các thuộc tính của tập dữ liệu

Thuộc tính	Mô tả
Customer ID	Mã định danh duy nhất cho mỗi khách hàng
Age	Tuổi của khách hàng
Gender	Giới tính của khách hàng (Nam/Nữ)
Item Purchased	Mặt hàng đã được khách hàng mua
Category	Thể loại của mặt hàng đã mua
Purchase Amount (USD)	Số tiền mua bằng USD
Location	Vị trí nơi thực hiện giao dịch mua
Size	Kích thước của sản phẩm đã mua
Color	Màu sắc của sản phẩm đã mua
Season	Mùa mà giao dịch mua được thực hiện
Review Rating	Xếp hạng do khách hàng đưa ra cho mặt hàng đã mua


Subscription Status	Chỉ ra liệu khách hàng có đăng ký hay không (Có/Không)
Shipping Type	Loại hình vận chuyển do khách hàng lựa chọn
Discount Applied	Chỉ ra liệu có áp dụng giảm giá cho giao dịch mua hay không (Có/Không)
Promo Code Used	Chỉ ra liệu mã khuyến mại có được sử dụng để mua hàng hay không (Có/Không)
Previous Purchases	Tổng số giao dịch được khách hàng thực hiện tại cửa hàng, không bao gồm giao dịch đang diễn ra
Payment Method	Phương thức thanh toán được khách hàng ưa chuộng nhất
Frequency of Purchases	Tần suất khách hàng thực hiện mua hàng (ví dụ: Hàng tuần, Hai tuần một lần, Hàng tháng)

3.1.3. Trực quan hóa dữ liệu



Hình 3.3. Trực quan hóa mối quan hệ giữa Age và Purchase Amount

Tại hình 3.2, hiển thị mối quan hệ giữa hai thuộc tính Age (Tuổi) trên trục X và Purchase Amount (USD) (Số tiền mua hàng) trên trục Y. Màu sắc của các điểm dữ liệu biểu thị giá trị của Purchase Amount (USD), với phổ màu trải dài từ xanh (giá trị thấp) đến vàng cam (giá trị cao). Dữ liệu phân bố khá dàn trải, trong đó nhóm khách hàng trẻ (18-40 tuổi) có mật độ cao hơn nhưng chủ yếu chi tiêu thấp. Khi độ tuổi tăng (40-70 tuổi), xuất hiện nhiều điểm dữ liệu có giá trị mua hàng cao hơn.



Hình 3.4. Trực quan hóa mối quan hệ giữa Gender và Purchase Amount

Tại hình 3.3, hiển thị mối quan hệ giữa Gender (Giới tính) trên trục X và Purchase Amount (USD) (Số tiền mua hàng) trên trục Y. Màu sắc của các điểm dữ liệu biểu thị giá trị của Purchase Amount (USD), với phổ màu trải dài từ xanh (giá trị thấp) đến vàng cam (giá trị cao). Dữ liệu được chia thành hai nhóm: Male (Nam) và Female (Nữ). Phân bố dữ liệu dọc theo trục Y cho thấy mức chi tiêu trải dài từ thấp đến cao ở cả hai giới. Màu sắc của điểm dữ liệu khá đồng đều giữa hai nhóm, cho thấy không có sự khác biệt rõ rệt về xu hướng chi tiêu giữa nam và nữ.

3.2. Xây dựng sản phẩm

3.2.1 Tiền xử lý dữ liệu

Trong quá trình xây dựng mô hình học máy, tiền xử lý dữ liệu là một bước quan trọng để đảm bảo chất lượng và hiệu quả của mô hình. Dữ liệu thô thường chứa các giá trị phân loại (categorical data), tức là các dữ liệu phi số học, chẳng hạn như phương thức thanh toán, màu sắc sản phẩm, hoặc vị trí địa lý.

2. Tải tệp dữ liệu

```
data = pd.read_csv('data/shopping_behavior_updated.csv')
```

```
unique_values = data["Frequency of Purchases"].unique()  
print(unique_values)
```

```
['Fortnightly' 'Weekly' 'Annually' 'Quarterly' 'Bi-Weekly' 'Monthly'  
 'Every 3 Months']
```

```
unique_values = data["Payment Method"].unique()  
print(unique_values)
```

```
['Venmo' 'Cash' 'Credit Card' 'PayPal' 'Bank Transfer' 'Debit Card']
```

```
unique_values = data["Shipping Type"].unique()  
print(unique_values)
```

Hình 3.5. Đọc tệp dữ liệu

Kiểm tra các dữ liệu có trong thuộc tính, loại bỏ dữ liệu customerid để không bị ảnh hưởng khi xử lý dữ liệu và đổi dữ liệu thời gian từ chữ thành số

```
import pandas as pd

# Đọc dữ liệu
data = pd.read_csv('data/shopping_behavior_updated.csv')

# Chọn các cột cần one-hot encoding
columns_to_encode = [
    "Payment Method", "Shipping Type", "Season", "Color", "Size", "Location",
    "Category", "Item Purchased"
]

# Thực hiện One-Hot Encoding
data_encoded = pd.get_dummies(data, columns=columns_to_encode)

# Kiểm tra kết quả
print(data.head())

# Lưu lại dữ liệu đã mã hóa
data_encoded.to_csv('data/shopping_behavior_encoded.csv', index=False)
data = pd.read_csv('data/shopping_behavior_encoded.csv')
```

Hình 3.6. Mã hóa One-Hot Encoding

Trong bộ dữ liệu hành vi mua sắm, các cột như **Payment Method** (Phương thức thanh toán), **Shipping Type** (Loại vận chuyển), **Color** (Màu sắc), và **Size** (Kích cỡ) là những dữ liệu phân loại. Chúng tôi đã áp dụng kỹ thuật One-Hot Encoding để mã hóa những giá trị phân loại này thành các biến giả (dummy variables), giúp chúng trở nên khả thi cho các mô hình học máy.

Cụ thể, các bước thực hiện mã hóa như sau:

- Chọn các cột cần mã hóa, bao gồm **Payment Method**, **Shipping Type**, **Season**, **Color**, **Size**, **Location**, **Category**, và **Item Purchased**.
- Áp dụng phương pháp **One-Hot Encoding** để tạo các biến số nhị phân (0/1) cho từng giá trị phân loại.

Sau khi mã hóa One-Hot Encoding, các cột ban đầu đã được thay thế bằng các cột mới có giá trị nhị phân (0 và 1), giúp mô hình dễ dàng xử lý hơn và tăng cường tính chính xác trong quá trình huấn luyện mô hình.

3.2.2. Phân loại bằng SVM

Sử dụng thuật toán Support Vector Machine (SVM) cho bài toán phân loại khách hàng, dự đoán xem khách hàng có sử dụng mã giảm giá (Promo Code) hay không dựa trên các đặc điểm của họ.

Thuật toán SVM có thể được sử dụng để:

- Phân loại khách hàng thành các nhóm dựa trên hành vi mua sắm, đặc điểm nhân khẩu học, hoặc các yếu tố khác.
- Dự đoán khả năng khách hàng phản hồi với các chiến dịch marketing.
- Xác định khách hàng có nguy cơ rời bỏ (churn prediction).

Cách thức hoạt động của thuật toán SVM:

● **Chuẩn bị dữ liệu:**

- Dữ liệu được tải từ file CSV.
- Các biến phân loại (Gender, Promo Code Used) được mã hóa thành dạng số sử dụng LabelEncoder.
- Các đặc trưng (features) và biến mục tiêu (target) được chọn.
- Các biến phân loại đa giá trị (Category, Season) được mã hóa one-hot để chuyển đổi thành dạng số phù hợp cho SVM.
- Dữ liệu được chia thành tập huấn luyện (train) và tập kiểm tra (test).
- Các đặc trưng được chuẩn hóa (scaling) để đảm bảo tất cả các đặc trưng có cùng tỷ lệ.

● **Huấn luyện mô hình:**

- Mô hình SVM được khởi tạo với kernel tuyến tính (linear). Kernel tuyến tính phù hợp với dữ liệu có thể phân tách tuyến tính. Nếu dữ liệu phức tạp hơn, có thể sử dụng các kernel khác như RBF hoặc polynomial.
- Mô hình được huấn luyện trên tập huấn luyện đã được chuẩn hóa.

Độ chính xác: 0.7513				
Báo cáo phân loại:				
	precision	recall	f1-score	support
0	1.00	0.54	0.70	422
1	0.65	1.00	0.79	358
accuracy			0.75	780
macro avg	0.82	0.77	0.74	780
weighted avg	0.84	0.75	0.74	780

Hình 3.7. Kết quả phân loại thuật toán SVM

- Mô hình hoạt động tốt trong việc dự đoán khách hàng có sử dụng mã giảm giá (lớp 1) với độ phủ cao.
- Tuy nhiên, hiệu suất dự đoán khách hàng không sử dụng mã giảm giá (lớp 0) cần được cải thiện.

3.2.3. Phân loại bằng KNN

Thuật toán K-Nearest Neighbors (KNN) để phân loại khách hàng dựa trên các đặc điểm của họ. Mô hình dự đoán xem khách hàng có sử dụng mã giảm giá (Promo Code) hay không.

- Trong ngữ cảnh phân tích khách hàng, KNN có thể được sử dụng để:
 - Phân loại khách hàng thành các nhóm dựa trên hành vi mua sắm, đặc điểm nhân khẩu học, hoặc các yếu tố khác.
 - Dự đoán khả năng khách hàng phản hồi với các chiến dịch marketing.
 - Đề xuất sản phẩm cho khách hàng dựa trên sở thích của những khách hàng tương tự.

Cách thức hoạt động của thuật toán KNN:

- **Chuẩn bị dữ liệu:**
 - Dữ liệu được tải từ file CSV.

- Các biến phân loại (Gender, Promo Code Used) được mã hóa thành dạng số sử dụng LabelEncoder.
- Các đặc trưng (features) và biến mục tiêu (target) được chọn.
- Các biến phân loại đa giá trị (Category, Season) được mã hóa one-hot để chuyển đổi thành dạng số phù hợp cho KNN.
- Dữ liệu được chia thành tập huấn luyện (train) và tập kiểm tra (test).
- Các đặc trưng được chuẩn hóa (scaling) để đảm bảo tất cả các đặc trưng có cùng tỷ lệ.
- **Huấn luyện mô hình:**
 - Mô hình KNN được khởi tạo với số lượng láng giềng (K) là 5. Giá trị K có thể được điều chỉnh để tối ưu hóa hiệu suất của mô hình.
 - Mô hình được huấn luyện trên tập huấn luyện đã được chuẩn hóa.

Độ chính xác của KNN: 0.7090

Báo cáo phân loại KNN:

	precision	recall	f1-score	support
0	0.75	0.69	0.72	422
1	0.67	0.73	0.70	358
accuracy			0.71	780
macro avg	0.71	0.71	0.71	780
weighted avg	0.71	0.71	0.71	780

Hình 3.8. Kết quả phân loại thuật toán KNN

- Mô hình KNN cho thấy hiệu suất tương đối cân bằng giữa độ chính xác và độ phủ cho cả hai lớp.
- Tuy nhiên, độ chính xác tổng thể của mô hình (70.90%) có thể được cải thiện bằng cách điều chỉnh các tham số của mô hình hoặc sử dụng các kỹ thuật tiền xử lý dữ liệu khác nhau.


3.2.4. Phân cụm bằng K-means

Thuật toán K-means để **phân cụm khách hàng** dựa trên các đặc điểm số của họ, bao gồm tuổi, số tiền mua hàng, số lần mua hàng trước đó, đánh giá sản phẩm và tần suất mua hàng.

- Trong ngữ cảnh phân tích khách hàng, K-means được sử dụng để:
 - Phân nhóm khách hàng thành các phân khúc khác nhau dựa trên hành vi mua sắm và đặc điểm nhân khẩu học.
 - Xác định các nhóm khách hàng có đặc điểm tương đồng để áp dụng các chiến lược marketing phù hợp.
 - Tìm hiểu các mẫu hành vi mua sắm của khách hàng.

Cách thức hoạt động của thuật toán K-means:

- **Chuẩn bị dữ liệu**
- **Tìm số cụm tối ưu:**
 - Phương pháp Elbow được sử dụng để xác định số cụm tối ưu.
 - WCSS (Within-Cluster Sum of Squares) được tính toán cho các số cụm khác nhau (từ 1 đến 10).
 - Biểu đồ Elbow được vẽ để trực quan hóa kết quả và chọn số cụm tại điểm "khủy tay".
- **Phân cụm K-means:**
 - Mô hình K-means được khởi tạo với số cụm tối ưu (trong trường hợp này là 5).
 - Mô hình được huấn luyện trên dữ liệu đã được chuẩn hóa.
 - Các cụm được gán cho từng điểm dữ liệu.



Hình 3.9. Đồ thị Elbow của K-means

Silhouette Score - K-Means: 0.1479

Davies-Bouldin Index - K-Means: 1.6535

- Kết quả cho thấy việc phân cụm bằng K-means có thể không tạo ra các cụm rõ ràng và phân tách tốt trong trường hợp này.
- Silhouette Score và Davies-Bouldin Index cho thấy có thể cần thử nghiệm các phương pháp phân cụm khác hoặc điều chỉnh các tham số của K-means để cải thiện kết quả.

3.2.5. Thuật toán Hierarchical Clustering (phân cụm phân cấp)

Thuật toán Hierarchical Clustering (phân cụm phân cấp) để **phân cụm khách hàng** dựa trên các đặc điểm số của họ, tương tự như K-means.

- Hierarchical Clustering tạo ra một cấu trúc phân cấp các cụm, cho phép khám phá mối quan hệ giữa các cụm ở các mức độ khác nhau.
- Trong ngữ cảnh phân tích khách hàng, Hierarchical Clustering được sử dụng để:

- Phân nhóm khách hàng thành các phân khúc khác nhau dựa trên hành vi mua sắm và đặc điểm nhân khẩu học.
- Xác định các nhóm khách hàng có đặc điểm tương đồng để áp dụng các chiến lược marketing phù hợp.
- Hiểu được cấu trúc phân cấp của các nhóm khách hàng.

Cách thức hoạt động của thuật toán Hierarchical Clustering:

- **Chuẩn bị dữ liệu:**


- Dữ liệu được tải từ file CSV.
- Các cột số được chọn để phân cụm.
- Kiểm tra và xử lý các cột không phải số (nếu có). Trong trường hợp này, cột 'Frequency of Purchases' được mã hóa thành dạng số sử dụng LabelEncoder.
- Dữ liệu được chuẩn hóa (scaling) để đảm bảo tất cả các đặc trưng có cùng tỷ lệ.

- **Xác định số cụm tối ưu bằng Dendrogram:**

- Dendrogram được vẽ để trực quan hóa cấu trúc phân cấp của các cụm và xác định số cụm tối ưu.
- Dendrogram hiển thị khoảng cách giữa các cụm khi chúng được hợp nhất.
- Số lượng cụm tối ưu được xác định bằng cách chọn một đường cắt ngang dendrogram để tạo ra các cụm riêng biệt.

- **Phân cụm Hierarchical Clustering:**

- Mô hình AgglomerativeClustering được khởi tạo với số cụm tối ưu (trong trường hợp này là 5), phương pháp liên kết 'ward' và khoảng cách 'euclidean'.
- Mô hình được huấn luyện trên dữ liệu đã được chuẩn hóa.
- Các cụm được gán cho từng điểm dữ liệu.



Hình 3.10. Biểu đồ Dendrogram

Silhouette Score - Hierarchical Clustering: 0.0880

Davies-Bouldin Index - Hierarchical Clustering: 2.0147

- Kết quả cho thấy việc phân cụm bằng Hierarchical Clustering có thể không tạo ra các cụm rõ ràng và phân tách tốt trong trường hợp này.
- Silhouette Score và Davies-Bouldin Index đều cho thấy có thể cần thử nghiệm các phương pháp phân cụm khác hoặc điều chỉnh các tham số của Hierarchical Clustering để cải thiện kết quả.

3.2.6. Đánh giá kết quả

3.2.6.1. So sánh và đánh giá thuật toán SVM và KNN:

Độ chính xác (Accuracy): SVM cho kết quả độ chính xác cao hơn so với KNN trong bài toán này.

Độ chính xác (Precision) và Độ phủ (Recall):

SVM có khả năng dự đoán chính xác lớp 0 tốt hơn nhưng độ phủ thấp hơn.

- KNN có độ cân bằng tốt hơn giữa Precision và Recall cho cả hai lớp.

Điểm F1 (F1-score): SVM có điểm F1 cao hơn cho lớp 1, trong khi KNN có điểm F1 cao hơn cho lớp 0.


Khả năng xử lý dữ liệu:

- **SVM:** Hiệu quả với dữ liệu có số chiều cao và có thể tìm ra các ranh giới quyết định phức tạp.
- **KNN:** Đơn giản và dễ hiểu, nhưng hiệu suất giảm khi số chiều dữ liệu tăng.

Kết luận:

- SVM cho thấy hiệu suất tổng thể tốt hơn trong bài toán này, đặc biệt là về độ chính xác.
- KNN có ưu điểm về tính đơn giản và cân bằng giữa Precision và Recall.

3.2.6.2. So sánh và đánh giá thuật toán Hierarchical Clustering và K-means



Hình 3.11. Kết quả phân cụm Hierarchical và K-Means Clustering

Trực quan hóa kết quả:

- **Hierarchical Clustering (biểu đồ bên trái):**
 - Các cụm có vẻ phân tán và chồng chéo lên nhau, đặc biệt là ở vùng dữ liệu có mật độ cao.
 - Các cụm không có hình dạng rõ ràng và có thể không đại diện cho các nhóm khách hàng có ý nghĩa.
- **K-means (biểu đồ bên phải):**
 - Các cụm có vẻ được phân tách tốt hơn và có hình dạng rõ ràng hơn.
 - Các cụm có thể đại diện cho các nhóm khách hàng có hành vi mua sắm khác nhau.

Nhận xét chung:

- **K-means có hiệu suất tốt hơn Hierarchical Clustering** trong bài toán này, dựa trên cả trực quan hóa và các chỉ số đánh giá.
- **Hierarchical Clustering tạo ra các cụm không rõ ràng** và có sự chồng chéo lớn, có thể do dữ liệu không có cấu trúc phân cấp rõ ràng hoặc do lựa chọn tham số không phù hợp.
- **K-means tạo ra các cụm có hình dạng rõ ràng hơn** và phân tách tốt hơn, cho thấy nó phù hợp hơn với dữ liệu này.

KẾT LUẬN

Qua quá trình nghiên cứu và thực hiện đề tài "Phân cụm trên tập dữ liệu hành vi mua sắm khách hàng", nhóm đã đạt được các mục tiêu đề ra ban đầu, bao gồm việc áp dụng các thuật toán phân loại và phân cụm để phân tích dữ liệu khách hàng. Đề tài đã tiến hành tiền xử lý dữ liệu, sử dụng mã hóa One-Hot Encoding cho các giá trị phân loại, sau đó áp dụng thuật toán SVM và KNN để phân loại khách hàng dựa trên hành vi mua sắm và dự đoán khả năng sử dụng mã giảm giá. Tiếp theo, đề tài đã sử dụng thuật toán K-means và Phân cụm phân cấp (Hierarchical Clustering) để phân nhóm khách hàng dựa trên các đặc điểm số như tuổi, thu nhập và tần suất mua hàng. Kết quả phân cụm đã cung cấp một cái nhìn tổng quan về các nhóm khách hàng tiềm năng, giúp định hướng cho các chiến dịch marketing trong tương lai.

Tuy nhiên, vẫn còn một số hạn chế trong quá trình thực hiện, như việc phân cụm bằng K-means và Phân cụm phân cấp chưa tạo ra các nhóm phân tách rõ ràng. Các chỉ số Silhouette Score và Davies-Bouldin Index cho thấy khả năng phân cụm chưa thực sự tối ưu, do đó cần tiếp tục nghiên cứu và cải thiện bằng cách thử nghiệm các phương pháp phân cụm khác hoặc tinh chỉnh tham số.

Trong tương lai, để nâng cao hiệu quả và độ chính xác của mô hình, nhóm cần thực hiện các cải tiến như sau cần **hoàn thiện các chức năng hiện có**: Cần điều chỉnh các tham số của các thuật toán phân cụm, đặc biệt là K-means và Phân cụm phân cấp, để cải thiện khả năng phân cụm. Việc thử nghiệm với các phương pháp phân cụm khác như DBSCAN cũng có thể mang lại kết quả khả quan hơn. **Áp dụng các kỹ thuật tiên tiến hơn**: Sử dụng các mô hình học sâu (Deep Learning) hoặc các thuật toán phân cụm cải tiến như Gaussian Mixture Models (GMM) có thể giúp cải thiện khả năng phân tích và phân loại khách hàng. **Mở rộng phạm vi dữ liệu**: Tăng cường dữ liệu với các yếu tố khác như dữ liệu hành vi online hoặc các dữ liệu từ mạng xã hội có thể giúp mô hình dự đoán tốt hơn. Những hướng phát triển này sẽ giúp nâng cấp hệ thống phân tích khách hàng, từ đó hỗ trợ doanh nghiệp đưa ra các quyết định marketing chính xác và hiệu quả hơn.

DANH MỤC TÀI LIỆU THAM KHẢO

- [1] Ultralytics, “Tích hợp Ultralytics với JupyterLab,” [Online]. Available: <https://docs.ultralytics.com/vi/integrations/jupyterlab/>. [Accessed: 20-Mar-2025].
- [2] DVMS, “Tổng quan về Data Mining (P1): Khai phá dữ liệu là gì?,” [Online]. Available: <https://dvms.com.vn/tin-tuc/big-data/75968-tong-quan-ve-data-mining-p1-khai-pha-du-lieu-la-gia.html>. [Accessed: 21-Mar-2025].
- [3] Thái, P. K. (2022). Bài giảng Phân cụm dữ liệu 2022.
- [4] Phạm, C. Đ. (2013, 04 25). Tổng quan về phân lớp dữ liệu trong khai phá dữ liệu. 123doc. Retrieved December 17, 2022, from <https://123docz.net/trich-doan/2193321-tong-quan-ve-phan-lop-du-lieu-trong-khai-pha-du-lieu-u.htm>
- [5] Kumar, V., & Singh, S. (2018). Customer Segmentation using K-Means Clustering Technique. International Journal of Computer Applications, 182(24), 23-27.
- [6] Hartigan, J. A., & Wong, M. A. (1979). Algorithm AS 136: A K-Means Clustering Algorithm. Journal of the Royal Statistical Society. Series C (Applied Statistics), 28(1), 100-108.
- [7] Zhang, T., Ramakrishnan, R., & Livny, M. (1996). BIRCH: An Efficient Data Clustering Method for Very Large Databases. Proceedings of the ACM SIGMOD International Conference on Management of Data, 25(2), 103-114.
- [8] Berkhin, P. (2006). A Survey of Clustering Data Mining Techniques. In Grouping Multidimensional Data (pp. 25-71). Springer.